



UNIVERSIDADE FEDERAL DO OESTE DO PARÁ
INSTITUTO DE ENGENHARIA E GEOCIÊNCIA

**Classificação de Sentimentos em Avaliações de Produtos
Alimentícios utilizando Machine Learning com Scikit-Learn
Inteligência Artificial (Tarde)**

Sandra Rocha dos Remédios, 2020005699

Santarém, PA
2026

1. Introdução

O crescimento do comércio eletrônico aumentou significativamente a quantidade de avaliações publicadas por consumidores sobre produtos e serviços. Estas avaliações representam uma importante fonte de informação para as empresas, permitindo compreender a satisfação dos clientes, identificar problemas e orientar melhorias. Entretanto, analisar manualmente milhares de comentários torna-se inviável devido ao grande volume de dados. Nesse contexto, técnicas de Inteligência Artificial, especialmente o Aprendizado de Máquina (Machine Learning), podem automatizar esse processo por meio da classificação de sentimentos. Neste projeto foi desenvolvido um modelo capaz de identificar automaticamente se uma avaliação de produto possui sentimento positivo ou negativo, utilizando técnicas de Processamento de Linguagem Natural (PLN) e a biblioteca Scikit-Learn.

2. Problema

Com o crescimento do comércio eletrônico e das plataformas digitais, consumidores passaram a compartilhar suas experiências por meio de avaliações e comentários sobre produtos adquiridos. Essas informações representam uma importante fonte de dados para empresas, pois permitem compreender a percepção dos clientes sobre a qualidade dos produtos e dos serviços oferecidos. No entanto, o grande volume de avaliações geradas diariamente torna inviável a análise manual dessas informações. Além de demandar tempo e recursos humanos, esse processo está sujeito a falhas e dificulta a obtenção de respostas rápidas para apoiar a tomada de decisões.

Nesse contexto, técnicas de Inteligência Artificial e Aprendizado de Máquina surgem como alternativas eficientes para automatizar a análise de sentimentos em textos. A classificação automática permite identificar se uma avaliação expressa uma opinião positiva ou negativa, fornecendo informações relevantes para monitorar a satisfação dos consumidores, identificar oportunidades de melhoria e apoiar estratégias de negócios. Diante desse cenário, este projeto busca responder à seguinte questão de pesquisa:

“Como utilizar técnicas de Machine Learning para classificar automaticamente avaliações de produtos alimentícios em sentimentos positivos ou negativos, de forma eficiente e confiável?”

A partir dessa problemática, foi desenvolvido um modelo de classificação utilizando a biblioteca Scikit-Learn e o conjunto de dados **Amazon Fine Food Reviews**, aplicando técnicas de Processamento de Linguagem Natural para transformar textos em informações que podem ser interpretadas pelo algoritmo de aprendizado de máquina.

3. Objetivos e Fundamentação Teórica

O presente projeto tem como objetivo desenvolver um modelo de Machine Learning capaz de classificar automaticamente avaliações de produtos alimentícios em sentimentos positivos ou negativos, utilizando técnicas de Processamento de Linguagem Natural (PLN) e a biblioteca Scikit-Learn. Para alcançar esse objetivo, foram definidos os seguintes objetivos específicos:

- Estudar conceitos relacionados à Inteligência Artificial, Machine Learning e Processamento de Linguagem Natural;
- Preparar a base de dados Amazon Fine Food Reviews para o treinamento do modelo;
- Implementar um algoritmo de classificação utilizando a biblioteca Scikit-Learn;
- Avaliar o desempenho do modelo por meio das métricas de Accuracy, Precision, Recall e F1-Score;
- Demonstrar a capacidade do sistema em classificar automaticamente novas avaliações de produtos.

A Inteligência Artificial (IA) é uma área da Ciência da Computação voltada ao desenvolvimento de sistemas capazes de executar tarefas que normalmente exigiriam inteligência humana, como reconhecimento de padrões, aprendizado e tomada de decisões. Dentro desse contexto, o Machine Learning (Aprendizado de Máquina) permite que computadores aprendam a partir de exemplos previamente conhecidos, identificando padrões nos dados e realizando previsões sobre novas informações. Neste projeto foi utilizada uma abordagem de aprendizado supervisionado, na qual o modelo é treinado com avaliações previamente classificadas como positivas ou negativas.

Como os dados utilizados são textos escritos por consumidores, foi necessário empregar técnicas de Processamento de Linguagem Natural (PLN), responsáveis por transformar a linguagem humana em representações numéricas que possam ser interpretadas pelo algoritmo de aprendizado. Para essa transformação foi utilizada a técnica TF-IDF (Term Frequency–Inverse Document Frequency), que atribui maior importância às palavras mais relevantes de cada comentário, reduzindo a influência de termos muito frequentes e pouco informativos.

Por fim, foi escolhido o algoritmo Multinomial Naive Bayes, amplamente utilizado em tarefas de classificação de textos devido à sua simplicidade, baixo custo computacional e bom desempenho em problemas de análise de sentimentos. A combinação entre TF-IDF e Naive Bayes constitui uma abordagem consolidada na literatura para aplicações de classificação textual, tornando-se adequada para os objetivos deste projeto.

4. Dataset Utilizado

Para o desenvolvimento deste projeto foi utilizado o conjunto de dados Amazon Fine Food Reviews, uma base pública amplamente empregada em pesquisas e projetos relacionados à análise de sentimentos e ao Processamento de Linguagem Natural. Esse conjunto de dados reúne avaliações de consumidores sobre produtos alimentícios comercializados na plataforma Amazon, contendo informações como o texto da avaliação, a nota atribuída ao produto e outros dados complementares.

Neste trabalho, foram utilizadas apenas as colunas Text, que contém o comentário escrito pelo consumidor, e Score, que representa a nota atribuída ao produto em uma escala de 1 a 5. Para simplificar o problema de classificação, as avaliações com notas 4 e 5 foram consideradas como sentimentos positivos, enquanto as avaliações com notas 1 e 2 foram classificadas como sentimentos negativos. As avaliações com nota 3 foram removidas da base de dados por apresentarem opiniões neutras, o que poderia dificultar o treinamento do modelo. Após essa etapa de seleção e tratamento dos dados, a coluna Text foi renomeada para

comentário, tornando a estrutura do conjunto de dados mais adequada ao desenvolvimento da aplicação. Em seguida, os dados foram divididos em conjuntos de treinamento e teste, permitindo que o modelo aprendesse os padrões presentes nas avaliações e, posteriormente, fosse avaliado utilizando dados que não participaram do treinamento. A utilização do Amazon Fine Food Reviews foi escolhida por se tratar de uma base de dados consolidada na literatura, contendo um grande volume de avaliações reais escritas por consumidores. Essa característica contribui para o treinamento de modelos de Machine Learning mais robustos e para a obtenção de resultados confiáveis na tarefa de classificação automática de sentimentos.

5. Metodologia e Tecnologias Utilizadas

O desenvolvimento deste projeto foi realizado seguindo as etapas clássicas de um processo de Machine Learning para classificação de textos. Inicialmente, foi realizada a importação do conjunto de dados Amazon Fine Food Reviews, contendo avaliações de consumidores sobre produtos alimentícios comercializados na plataforma Amazon. Em seguida, foram selecionadas apenas as colunas necessárias para a pesquisa, correspondentes ao texto da avaliação (*Text*) e à nota atribuída pelo usuário (*Score*).

Na etapa de preparação dos dados, as avaliações foram convertidas em duas classes de sentimentos. As avaliações com notas 4 e 5 foram classificadas como Positivo, enquanto as avaliações com notas 1 e 2 foram classificadas como Negativo. As avaliações com nota 3 foram removidas do conjunto de dados por apresentarem sentimentos neutros, permitindo que o modelo realizasse uma classificação binária mais consistente. Após o pré-processamento, o conjunto de dados foi dividido em duas partes: uma destinada ao treinamento do modelo e outra utilizada para testes e validação. Essa divisão possibilitou avaliar a capacidade de generalização do algoritmo, verificando seu desempenho em dados que não participaram da etapa de treinamento.

Para transformar os comentários em representações numéricas compreensíveis pelo algoritmo, foi utilizada a técnica TF-IDF (Term Frequency–Inverse Document Frequency), responsável por atribuir maior relevância às palavras mais importantes presentes nos textos. Essa técnica é amplamente empregada em aplicações de Processamento de Linguagem Natural por permitir uma representação eficiente dos documentos em formato vetorial. Como algoritmo de classificação foi utilizado o Multinomial Naive Bayes, escolhido por apresentar bom desempenho em problemas de classificação textual, além de possuir baixo custo computacional e rápida execução. O treinamento e a avaliação do modelo foram realizados por meio da biblioteca Scikit-Learn, utilizando a estrutura Pipeline, que integra as etapas de vetorização dos textos e classificação em um único fluxo de processamento.

O desempenho do modelo foi avaliado por meio das métricas Accuracy (Acurácia), Precision (Precisão), Recall (Revocação) e F1-Score, além da análise da Matriz de Confusão, que permite visualizar a quantidade de classificações corretas e incorretas realizadas pelo algoritmo. Essas métricas são amplamente utilizadas na avaliação de modelos de classificação e possibilitam uma análise detalhada da qualidade das previsões obtidas. O desenvolvimento da aplicação foi realizado utilizando a linguagem de programação Python, executada no ambiente Google Colab, que oferece suporte à execução de notebooks na nuvem sem necessidade de instalação local. Para manipulação e análise dos dados foi empregada a biblioteca Pandas, enquanto a biblioteca Scikit-Learn foi utilizada para a implementação do

modelo de aprendizado de máquina, vetorização dos textos, treinamento e avaliação do algoritmo. A biblioteca Matplotlib foi utilizada para a geração da Matriz de Confusão, permitindo a visualização gráfica dos resultados. Por fim, a biblioteca Joblib foi empregada para salvar o modelo treinado, possibilitando sua reutilização em futuras aplicações sem a necessidade de um novo treinamento.

6. Implementação e Resultados

A implementação do projeto foi realizada utilizando a linguagem de programação Python, no ambiente Google Colab, por meio da biblioteca Scikit-Learn, que disponibiliza ferramentas para criação, treinamento e avaliação de modelos de Machine Learning.

Inicialmente, o conjunto de dados Amazon Fine Food Reviews foi carregado para o ambiente de desenvolvimento e submetido a uma etapa de preparação. Foram selecionadas apenas as colunas Text, contendo o comentário do consumidor, e Score, representando a nota atribuída ao produto. Em seguida, as avaliações foram convertidas em duas classes de sentimentos: avaliações com notas 4 e 5 foram classificadas como Positivas, enquanto as avaliações com notas 1 e 2 foram classificadas como Negativas. As avaliações com nota 3 foram removidas por representarem uma opinião neutra.

Após o pré-processamento, os dados foram divididos em conjuntos de treinamento e teste utilizando a função `train_test_split()`, garantindo que o modelo fosse treinado em uma parte da base de dados e avaliado em outra, reduzindo o risco de sobreajuste (overfitting). Para transformar os comentários em dados numéricos, foi utilizada a técnica TF-IDF (Term Frequency–Inverse Document Frequency), responsável por representar cada texto como um vetor de características. Essa etapa permite que o algoritmo identifique padrões linguísticos presentes nas avaliações e realize a classificação dos sentimentos.

Como algoritmo de classificação foi utilizado o Multinomial Naive Bayes, implementado por meio de um Pipeline da biblioteca Scikit-Learn. Essa abordagem integra as etapas de vetorização dos textos e treinamento do modelo em um único fluxo de processamento, tornando a implementação mais organizada e eficiente. Após o treinamento, o modelo foi salvo utilizando a biblioteca Joblib, permitindo sua reutilização sem necessidade de novo treinamento. Para avaliar o desempenho do modelo, foram utilizadas as métricas Accuracy (Acurácia), Precision (Precisão), Recall (Revocação) e F1-Score, além da Matriz de Confusão, que permite visualizar graficamente a quantidade de classificações corretas e incorretas realizadas pelo algoritmo. Essas métricas possibilitam uma análise abrangente da qualidade do modelo e são amplamente utilizadas em problemas de classificação supervisionada.

Os resultados obtidos durante a execução do notebook demonstraram que o modelo foi capaz de identificar corretamente o sentimento predominante das avaliações presentes no conjunto de dados. As métricas calculadas evidenciam o desempenho alcançado pelo algoritmo na classificação dos comentários, enquanto a matriz de confusão permite verificar a distribuição dos acertos e erros entre as classes positiva e negativa.

```

accuracy_score(y_test, predicoes)

print(classification_report(y_test, predicoes))

```

...	precision	recall	f1-score	support
Negativo	0.89	0.30	0.45	16407
Positivo	0.89	0.99	0.94	88756
accuracy			0.89	105163
macro avg	0.89	0.65	0.69	105163
weighted avg	0.89	0.89	0.86	105163

Tabela 1 – Resultados do Modelo




Figura 1 – Matriz de Confusão

Os resultados obtidos demonstram que a combinação da técnica TF-IDF com o algoritmo Multinomial Naive Bayes foi eficiente para a classificação de sentimentos nas avaliações do conjunto Amazon Fine Food Reviews. O modelo alcançou 89% de acurácia, apresentando excelente desempenho na identificação de avaliações positivas. Apesar da menor taxa de detecção de avaliações negativas, influenciada pelo desbalanceamento da base de dados, o modelo mostrou-se adequado para a tarefa proposta, atingindo os objetivos estabelecidos neste projeto.

7. Conclusão

O desenvolvimento deste projeto possibilitou aplicar, na prática, conceitos de Inteligência Artificial, Machine Learning e Processamento de Linguagem Natural na classificação automática de sentimentos em avaliações de produtos alimentícios. A utilização da biblioteca Scikit-Learn, em conjunto com a técnica de vetorização TF-IDF e o algoritmo Multinomial Naive Bayes, permitiu a construção de um modelo capaz de identificar sentimentos positivos e negativos de forma automatizada. Os resultados obtidos demonstraram que o modelo apresentou um desempenho satisfatório, alcançando 89% de acurácia na classificação das avaliações do conjunto de dados Amazon Fine Food Reviews. Embora tenha apresentado menor desempenho na identificação de avaliações negativas, em razão do desbalanceamento da base de dados, o modelo mostrou-se eficiente para a tarefa proposta e atingiu os objetivos estabelecidos no início do projeto.

Além de contribuir para a compreensão das etapas envolvidas na construção de um modelo de aprendizado de máquina, este trabalho evidenciou a importância da análise automática de sentimentos como ferramenta de apoio à tomada de decisões em ambientes que lidam com grandes volumes de avaliações textuais. Como trabalhos futuros, recomenda-se a utilização de bases de dados balanceadas, a aplicação de técnicas mais avançadas de Processamento de Linguagem Natural e a avaliação de outros algoritmos de classificação, visando melhorar ainda mais o desempenho do modelo.

8. Agradecimentos

Durante o desenvolvimento deste projeto foi utilizada a ferramenta ChatGPT (OpenAI) como apoio à organização do trabalho, ao esclarecimento de conceitos relacionados à Inteligência Artificial e Machine Learning, à estruturação do relatório técnico, à elaboração inicial do código em Python e à revisão e correção textual do relatório, visando melhorar a clareza, a coerência e a adequação da linguagem acadêmica. Todo o conteúdo produzido com o auxílio da IA foi revisado, validado e adaptado pela equipe antes da implementação final. O código foi testado e ajustado de acordo com o conjunto de dados Amazon Fine Food Reviews, garantindo seu correto funcionamento. Além disso, a equipe realizou modificações na estrutura do projeto, revisou os textos, interpretou os resultados obtidos e efetuou as adaptações necessárias para atender aos objetivos propostos. Como limitações, observou-se que algumas sugestões geradas pela IA precisavam de adaptações para funcionar corretamente com a base de dados escolhida e com os requisitos específicos do projeto. Dessa forma, todas as etapas foram submetidas à validação humana, assegurando a qualidade, a confiabilidade e a consistência das informações apresentadas no relatório e na implementação do sistema.

9. Referências

BIRD, Steven; KLEIN, Ewan; LOPER, Edward. **Natural Language Processing with Python**. Sebastopol: O'Reilly Media, 2009.

MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHÜTZE, Hinrich. **Introduction to Information Retrieval**. Cambridge: Cambridge University Press, 2008.

PEDREGOSA, Fabian et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, Massachusetts, v. 12, p. 2825-2830, 2011.

MCGAULEY, Julian; LESKOVEC, Jure. **Amazon Fine Food Reviews Dataset**. Kaggle. Disponível em: <https://www.kaggle.com/datasets/snap/amazon-fine-food-reviews>. Acesso em: 1 jul. 2026.

GOOGLE. **Google Colaboratory**. Disponível em: <https://colab.research.google.com/>. Acesso em: 1 jul. 2026.